Informe técnico: Componente A (Data Mart analítico)

1. Introducción y alcance

Este documento describe el Data Mart de ventas que sirve de base al agente analítico de inteligencia artificial. Un Data Mart es una base de datos pequeña y ordenada, pensada para responder preguntas de negocio (cuánto se vendió, quién compró, qué canal rinde más). Se diferencia de un sistema operacional, que está diseñado para registrar cada venta en el momento en que ocurre.

El principio rector del trabajo es que el Data Mart contiene la verdad analítica del negocio: toda respuesta que entregue el agente debe salir de estos datos y de ninguna otra fuente.

El modelo representa el proceso de ventas y permite responder preguntas sobre ventas, rentabilidad, clientes, productos, canales, sucursales y tendencias en el tiempo. Soporta las siete preguntas mínimas del enunciado y tres preguntas adicionales propuestas por el equipo (sección 9). Para la implementación se utilizó SQLite, un motor de base de datos que guarda todo en un solo archivo y no requiere instalar un servidor, junto con Python para generar los datos de prueba y ejecutar las comprobaciones.

2. Datos de origen: operacional frente a analítico

Para diferenciar los datos operacionales de los analíticos, el equipo simuló un sistema operacional con tres tablas de prefijo `src_`: `src_ventas` (una fila por línea de venta), `src_productos` y `src_clientes_historial` (una fila por cada versión de segmento de un cliente). Estas tablas son planas, repiten textos y pueden traer datos incompletos, tal como ocurre en un sistema real. El Data Mart se construye a partir de ellas.

Los datos de prueba se generaron con un programa de semilla fija (42), de modo que cualquier integrante obtiene exactamente los mismos datos. El conjunto contiene 458 líneas de venta agrupadas en 222 tickets, entre el 3 de abril y el 30 de septiembre de 2026 (seis meses), con 24 clientes, 18 productos en 6 categorías, 3 canales y 4 sucursales. Además, incluye de forma intencional algunos registros imperfectos para demostrar cómo se tratan (sección 6).

Aspecto	Datos operacionales (`src_`)	Datos analíticos (Data Mart)
Propósito	Registrar las ventas	Analizar y responder preguntas
Estructura	Tablas planas con textos repetidos	Esquema estrella: hechos y dimensiones
Identificación	Códigos del sistema de origen	Claves sustitutas propias del Data Mart
Calidad	Pueden traer vacíos y códigos inexistentes	Validados, con tratamiento explícito de excepciones
Cálculos	No incluye ingreso neto ni margen	Ingreso neto, costo y margen calculados una sola vez

3. Diseño dimensional

3.1 Proceso de negocio y grano

El proceso de negocio modelado es la venta de productos a clientes, a través de distintos canales y sucursales.

El grano es el nivel de detalle de la tabla de hechos y se definió en una sola oración:

> *Una fila de FactVentas representa una línea de producto vendida dentro de un ticket de venta.*

Este es el punto de partida de todo el diseño. Al guardar el detalle más fino (cada producto de cada ticket), los datos pueden resumirse luego por producto, categoría, ticket, día, mes, cliente, canal o sucursal sin perder información.

3.2 Esquema estrella

[Insertar aquí el diagrama del esquema estrella]

El modelo tiene forma de estrella: una tabla de hechos en el centro (`FactVentas`), que guarda las ventas, rodeada por cinco dimensiones que describen el contexto de cada venta: cuándo, quién, qué, por qué canal y en qué sucursal. Cada dimensión se conecta directamente con la tabla de hechos.

Tabla	Rol	Filas cargadas
DimTiempo	Calendario	181 (un día por cada fecha entre el 3 de abril y el 30 de septiembre)
DimCliente	Clientes y su segmento	26 (24 clientes, 1 versión adicional por un cambio de segmento y 1 registro «Desconocido»)
DimProducto	Productos y categorías	19 (18 productos y «Desconocido»)
DimCanal	Canales de venta	4 (3 canales y «Desconocido»)
DimSucursal	Sucursales y ciudades	5 (4 sucursales y «Desconocida»)
FactVentas	Ventas	458

3.3 Dimensiones y jerarquías

Una jerarquía es un camino de lo más detallado a lo más general dentro de una dimensión. Permite «subir» o «bajar» el nivel de análisis, por ejemplo, pasar de ventas por día a ventas por mes.

Dimensión	Qué describe	Atributos principales	Jerarquía
DimTiempo	Cuándo ocurrió la venta	Fecha, año, trimestre, mes, día	Día → mes → trimestre → año

Dimensión	Qué describe	Atributos principales	Jerarquía
DimCliente	Quién compró	Identificador, nombre, segmento, fechas de vigencia	Cliente → segmento
DimProducto	Qué se vendió	Nombre, categoría, costo unitario	Producto → categoría
DimCanal	Por qué vía se vendió	Nombre del canal	Sin jerarquía
DimSucursal	Dónde se vendió	Nombre, ciudad	Sucursal → ciudad

3.4 Tabla de hechos

`FactVentas` contiene las cinco claves que la conectan con las dimensiones, el número de ticket y de línea, y las medidas numéricas de cada venta (cantidad, precio unitario, descuento, ingreso bruto, ingreso neto, costo total y margen bruto).

Su clave primaria está formada por dos campos juntos: `numero_ticket` y `numero_linea`. Esto garantiza que una misma línea de un mismo ticket no pueda cargarse dos veces. El campo `numero_ticket` es una dimensión degenerada: identifica la transacción pero no tiene tabla propia, porque no tiene atributos que describir. Se conserva en la tabla de hechos porque es indispensable para contar tickets y calcular el ticket promedio.

3.5 Claves sustitutas

Una clave sustituta es un número que el propio Data Mart asigna a cada fila de una dimensión (por ejemplo, `sk_cliente`), distinto del código que usa el sistema de origen (por ejemplo, `C005`). Se utilizan por cuatro razones:

1. Hacen al Data Mart independiente del sistema de origen: si ese sistema cambia o reutiliza códigos, el modelo no se rompe.
2. Permiten conservar el historial de un cliente, ya que cada versión necesita su propia clave (sección 5).
3. Permiten crear registros especiales, como «Desconocido», con la clave −1 (sección 6).
4. Hacen más simples y rápidas las uniones entre tablas, al ser números enteros.

3.6 Clasificación de las métricas

Tipo	Métricas	Cómo se utilizan
Aditivas	Cantidad, ingreso bruto, descuento, ingreso neto, costo total, margen bruto	Se pueden sumar por cualquier dimensión (por mes, canal, categoría, etc.)
No aditivas	Precio unitario, margen porcentual, ticket promedio	No se suman ni se promedian entre sí; se recalculan a partir de los totales

Tipo	Métricas	Cómo se utilizan
Semiaditivas	Ninguna en este modelo	Un ejemplo típico es el saldo de inventario, que se suma entre productos pero no entre fechas. Aparecería si se incorporara inventario al modelo

Un error frecuente es promediar porcentajes de margen de varios meses para obtener el margen del periodo. Lo correcto es dividir el margen total entre el ingreso neto total, y así lo hacen todas las consultas del Data Mart.

4. Reglas de cálculo

Las reglas se aplican una sola vez, durante la carga de datos, de modo que todas las consultas utilicen la misma definición oficial de cada indicador. Los montos se redondean a dos decimales.

Indicador	Regla	Significado
Ingreso bruto	Cantidad × precio unitario	Lo que se habría cobrado sin descuento
Descuento	Monto de rebaja registrado en la venta	Lo que se dejó de cobrar
Ingreso neto	Ingreso bruto − descuento	Lo efectivamente cobrado; base de todas las consultas de ventas
Costo total	Cantidad × costo unitario del producto	Lo que costó lo vendido. Si el producto no tiene costo registrado, queda vacío
Margen bruto	Ingreso neto − costo total	Ganancia antes de gastos
Margen porcentual	Margen bruto total ÷ ingreso neto total × 100	Rentabilidad relativa, siempre calculada sobre totales
Ticket promedio	Ingreso neto total ÷ número de tickets distintos	Valor medio de una compra

Ejemplo: una línea de 2 unidades a 50, con descuento de 10 y costo unitario de 20, tiene un ingreso bruto de 100, un ingreso neto de 90, un costo total de 40 y un margen bruto de 50 (55,6 % del ingreso neto). Para el ticket promedio, si un ticket tiene dos líneas de 90 y 110, su valor es 200 y cuenta como un solo ticket, no como dos.

5. Manejo de cambios históricos (SCD)

La pregunta de diseño obligatoria es: si un cliente cambia de segmento, ¿se reemplaza el valor anterior o se conserva la historia? Existen dos opciones habituales:

- Tipo 1: se sobrescribe el valor. Es más simple, pero se pierde el pasado.
- Tipo 2: se conserva la fila anterior y se crea una nueva con el valor actualizado.

Decisión del equipo: SCD Tipo 2 en DimCliente. Cada versión del cliente guarda su fecha de inicio, su fecha de fin (vacía si es la vigente) y un indicador de versión actual. Un ejemplo real de los datos de prueba es la clienta C005:

sk_cliente	id_cliente	Segmento	Inicio	Fin	Versión actual
5	C005	Regular	2026-01-01	2026-06-30	No
6	C005	Premium	2026-07-01	(vacío)	Sí

Efecto sobre las consultas del agente. Durante la carga, cada venta se asocia a la versión del cliente que estaba vigente en la fecha de esa venta: una compra de mayo queda en «Regular» y una de agosto en «Premium». Esto es esencial para la pregunta «¿qué segmento redujo más su volumen de compra?», que compara periodos. Con SCD Tipo 1, todo el historial de C005 pasaría a «Premium» y el volumen que compró cuando era «Regular» desaparecería de ese segmento, lo que daría una respuesta incorrecta.

Consecuencias de la decisión. La dimensión tiene más filas que clientes reales, por lo que para contar clientes se utiliza el identificador del cliente (`id_cliente`) y no la clave sustituta. Por esa razón, el ranking de clientes (Q9) agrupa por `id_cliente`, para unir todas las versiones de un mismo cliente.

6. Registros desconocidos, valores faltantes y claves sin correspondencia

En datos reales siempre hay registros incompletos o inconsistentes. El equipo definió un tratamiento explícito para cada situación:

Situación	Ejemplo	Tratamiento
Dato no informado	Venta sin cliente	Se asocia al registro «Desconocido» de la dimensión (clave −1)
Clave sin correspondencia	Venta con el cliente C999, que no existe	Se asocia al mismo registro «Desconocido»
Medida faltante	Producto sin costo registrado	El costo y el margen quedan vacíos (NULL); no se reemplazan por cero

Se descartó eliminar estas ventas porque el ingreso total del Data Mart no coincidiría con el del origen, y se descartó dejar la clave vacía porque rompería la integridad referencial. Tampoco se usa el valor cero para el costo, porque haría parecer que el producto tuvo un margen de 100 %. Al quedar vacío, las sumas lo ignoran y el agente puede advertirlo en su respuesta.

Los datos de prueba incluyen estos casos a propósito: 5 tickets (13 líneas) con cliente desconocido (tres con un cliente inexistente y dos sin cliente), 1 línea con un producto inexistente, 1 ticket (2 líneas) sin canal y un producto sin costo registrado. Como resultado, 22 líneas quedaron sin costo: la del producto desconocido y las del producto sin costo. Los rankings excluyen el registro «Desconocido», y el agente debe advertir cuando existan ventas en esa categoría.

7. Prevención de duplicidades

Para evitar duplicar ingresos, cantidades o conteos de transacciones, el modelo aplica tres medidas: la clave primaria compuesta (`numero_ticket`, `numero_linea`) impide cargar dos veces la misma línea; los tickets se cuentan siempre con valores distintos (no contando filas); y un control específico verifica que no existan grupos duplicados (sección 10).

8. Implementación y reproducibilidad

El Data Mart se construye con cinco scripts SQL y dos programas de Python, que se ejecutan en un orden definido:

Archivo	Función
`generar_datos.py`	Genera los datos operacionales de prueba (semilla fija)
`01_estructura.sql`	Crea las tablas operacionales, las dimensiones, la tabla de hechos, las claves, las restricciones y los registros «Desconocido»
`02_datos_src.sql`	Contiene los datos operacionales generados
`03_carga_etl.sql`	Carga las dimensiones (con SCD Tipo 2 en clientes) y la tabla de hechos, aplicando las reglas de cálculo
`04_consultas.sql`	Catálogo de consultas parametrizadas del agente
`05_controles.sql`	Controles de integridad y conciliación
`construir_y_probar.py`	Construye la base, ejecuta controles y consultas y genera el archivo final de entrega

La carga sigue este orden: primero las dimensiones (canal, sucursal, producto, tiempo y cliente) y al final la tabla de hechos. El archivo final `Equipo04_Datamart.sql` reúne los cinco scripts y se verificó reconstruyendo la base de datos desde cero únicamente con él, lo que obtuvo las mismas 458 filas en la tabla de hechos.

9. Consultas analíticas

El agente accede al Data Mart mediante un catálogo de consultas parametrizadas: plantillas SQL con espacios (parámetros) que el agente completa con los valores de la pregunta, como fechas, categorías o canales. Así, el agente solo puede ejecutar consultas previamente definidas y nunca concatena texto del usuario dentro del SQL, lo que evita consultas no autorizadas.

9.1 Preguntas mínimas del enunciado

Id	Pregunta	Parámetros	Resultado con los datos de prueba
Q1	¿Cuál fue el ingreso neto por mes?	Desde, hasta	Abril 5,328.97; mayo 4,445.23; junio 6,712.69; julio 7,213.18; agosto 5,705.12; septiembre 7,335.41

Id	Pregunta	Parámetros	Resultado con los datos de prueba
Q2	¿Cuáles son las cinco categorías con mayor margen bruto?	Desde, hasta, n	Deportes 6,952.59; Ropa 4,355.98; Electronica 3,644.69; Hogar 2,642.01; Juguetes 1,996.09
Q3	¿Qué sucursal presenta el ticket promedio más alto?	Desde, hasta, n	Sucursal Norte, con 198.00 (57 tickets)
Q4	¿Qué segmento de clientes redujo más su volumen de compra?	Dos periodos	Ocasional: de 63 a 50 unidades (−13). Regular: 130 a 137 (+7). Premium: 188 a 332 (+144)
Q5	¿Qué canal concentra el mayor valor de ventas?	Desde, hasta, n	Tienda Fisica, con 21,498.06
Q6	Comparar el margen de dos canales en los últimos tres meses	Dos canales, desde, hasta	Margen porcentual, julio a septiembre: Tienda Fisica 53.96 %, 54.75 % y 54.37 %; Web 55.15 %, 53.99 % y 56.30 %
Q7	¿Qué producto lidera las ventas dentro de una categoría y periodo?	Categoría, desde, hasta	En Electronica, de julio a septiembre: Teclado Mecanico, con 40 unidades y 2,170.19

Los nombres se muestran tal como están almacenados (sin tildes). Se incluye además la consulta de apoyo Q0, que informa el periodo disponible (3 de abril al 30 de septiembre de 2026) y permite al agente interpretar expresiones como «últimos tres meses». En la consulta Q3, el valor alto se explica en parte porque el catálogo de prueba incluye productos de precio elevado.

9.2 Preguntas adicionales propuestas por el equipo

Id	Pregunta	Por qué aporta valor al negocio	Resultado
Q8	¿Cuál es el margen porcentual por categoría?	El margen en dinero engaña: una categoría puede vender mucho y ser poco rentable. El porcentaje permite decidir dónde enfocar esfuerzos	Juguetes 61.34 %; Ropa 61.16 %; Hogar 56.62 %; Electronica 53.17 %; Deportes 51.41 %; Alimentos 35.07 %
Q9	¿Quiénes son los diez clientes que más compran?	Mide la dependencia del negocio de pocos clientes y permite diseñar acciones de fidelización	El primero es C007 (Laura Mora), con 4,084.62
Q10	¿Cuánto descuento se otorga por canal?	Detecta canales donde se cede margen mediante descuentos	Tienda Fisica 1.09 %; Web 0.85 %; WhatsApp 0.34 % del ingreso bruto

10. Controles de calidad y conciliación

10.1 Controles ejecutados

Control	Qué verifica	Resultado esperado	Resultado obtenido
C1	Que ninguna venta apunte a una dimensión inexistente (integridad referencial)	0 casos	0 casos en las cinco dimensiones
C2	Que no haya líneas de ticket duplicadas	0 duplicados	0 duplicados
C3	Que los totales del Data Mart coincidan con los datos de origen	Diferencia 0	Todas las comparaciones en OK (ver 10.2)
C4	Cuántas ventas se cargaron en «Desconocido» o sin costo	Coherente con los casos de prueba	Cliente: 13 líneas; producto: 1; canal: 2; sucursal: 0; sin costo: 22
C5	Que cada cliente tenga exactamente una versión vigente	0 casos	0 casos
C6	Que se conserve el historial de los clientes con cambios	Al menos un cliente	C005 con dos versiones
C7	Que cada venta apunte a la versión del cliente vigente en su fecha	0 casos	0 casos
C8	Que se cumplan las reglas de cálculo en todas las filas	0 casos	0 casos

[Insertar aquí las capturas de pantalla de los controles C1 a C8]

10.2 Conciliación de totales contra los datos de origen

Indicador	Datos de origen	Data Mart	Diferencia	Estado
Líneas de venta	458	458	0	OK
Tickets distintos	222	222	0	OK
Cantidad vendida	929	929	0	OK
Ingreso bruto	37,092.88	37,092.88	0.00	OK
Descuento	352.28	352.28	0.00	OK
Ingreso neto	36,740.60	36,740.60	0.00	OK

La conciliación demuestra que no se perdió ni se duplicó ninguna venta durante la carga, incluidas las ventas asociadas a registros «Desconocido».

11. Limitaciones y mejoras futuras del Data Mart

- **Datos sintéticos.** Los datos fueron generados para la demostración; con datos reales deberán revisarse las reglas de limpieza.
- **Costo vigente.** El costo unitario se guarda en la dimensión de productos con su valor actual, sin historial; si el costo cambiara en el tiempo, el margen de ventas antiguas no reflejaría el costo de ese momento. Una mejora sería aplicar SCD Tipo 2 también a los productos.
- **Un solo proceso de negocio.** El modelo cubre ventas; no incluye devoluciones ni inventario. Con inventario aparecerían las métricas semiaditivas.
- **Una sola moneda y un único calendario.** No se contemplan monedas ni feriados.
- **Motor de base de datos.** SQLite es adecuado para un prototipo; para un uso empresarial se recomendaría un motor con servidor y gestión de usuarios y permisos.